



Cartera de Proyectos de Data Analytics

10 Proyectos con Datasets Comerciales Reales

Diplomado de Especialización en Data Analytics

20 de marzo de 2026

Resumen Ejecutivo

10 proyectos que cubren necesidades reales de negocio

Proyectos 1-5

1. Cancelaciones Hoteleras
2. Conversión E-Commerce
3. Telemarketing Bancario
4. Riesgo Crediticio
5. Segmentación por Ingreso

Proyectos 6-10

6. Subastas Automotrices
7. Detección de Phishing
8. Churn en E-Commerce
9. Fraude en Seguros
10. Retención de Talento

Total registros: > 400,000 **Variables:** 15-33 por dataset **Sectores:** 8 industrias

Proyecto 1: Predicción de Cancelaciones Hoteleras

 Sector: Hotelería y Turismo — 119,390 registros — 32 variables

Objetivo de Negocio

Reducir la tasa de cancelaciones de reservas hoteleras mediante un modelo predictivo que identifique reservas con alta probabilidad de cancelación, permitiendo al hotel implementar estrategias proactivas de retención (descuentos, confirmaciones anticipadas, overbooking controlado).

Contexto

El dataset contiene reservas reales de un **hotel urbano** y un **hotel resort** en Portugal (2015–2017). Incluye datos de huéspedes, fechas, canales de distribución, tipo de habitación y estado de la reserva. Publicado por Antonio, Almeida & Nunes (2019).

Datos Clave

- **Fuente:** Kaggle / ScienceDirect
- **Registros:** 119,390
- **Variables:** 32
- **Target:** is_canceled
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↑ Revenue management
- ↓ Pérdidas por no-show
- ↑ Ocupación efectiva

Proyecto 1: Diccionario de Datos

Hotel Booking Demand — Variables Principales

Variable	Tipo	Descripción
hotel	Categ.	Tipo: “Resort Hotel” o “City Hotel”
is_canceled	Binaria	1 si la reserva fue cancelada, 0 si no
lead_time	Num.	Días entre reserva y llegada
arrival_date_year	Num.	Año de llegada (2015–2017)
arrival_date_month	Categ.	Mes de llegada
stays_in_weekend_nights	Num.	Noches de fin de semana
stays_in_week_nights	Num.	Noches entre semana
adults / children / babies	Num.	Composición del grupo
meal	Categ.	Tipo de comida contratada
country	Categ.	País de origen del huésped
market_segment	Categ.	Segmento de mercado (Online TA, Groups...)
distribution_channel	Categ.	Canal de distribución
deposit_type	Categ.	Tipo de depósito (No Deposit, Non Refund...)
customer_type	Categ.	Tipo de cliente (Transient, Contract...)
adr	Num.	Tarifa diaria promedio (Average Daily Rate)
total_of_special_requests	Num.	Núm. de solicitudes especiales

Proyecto 2: Conversión de Visitantes en Compradores Online

 Sector: E-Commerce — 12,330 registros — 18 variables

Objetivo de Negocio

Aumentar la tasa de conversión de una tienda online identificando en tiempo real qué visitantes tienen alta probabilidad de compra. Esto permite personalizar la experiencia: mostrar ofertas especiales, activar pop-ups de descuento o priorizar el soporte de chat para visitantes con alta intención de compra.

Contexto

Dataset de **UCI Machine Learning Repository** con sesiones web de una tienda online durante 1 año. Cada fila es una sesión única de un usuario distinto. Solo el **15.5 %** de las sesiones terminaron en compra. Incluye métricas de Google Analytics y datos del visitante.

Datos Clave

- **Fuente:** UCI ML Repository
- **Registros:** 12,330
- **Variables:** 18 (10 num., 8 categ.)
- **Target:** Revenue
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↑ Tasa de conversión
- ↑ Ingreso por visitante
- ↓ Costo de adquisición

Proyecto 2: Diccionario de Datos

 Online Shoppers Purchasing Intention — Todas las Variables

Variable	Tipo	Descripción
Administrative	Num.	Páginas administrativas visitadas
Administrative_Duration	Num.	Tiempo en páginas administrativas (seg.)
Informational	Num.	Páginas informativas visitadas
Informational_Duration	Num.	Tiempo en páginas informativas (seg.)
ProductRelated	Num.	Páginas de producto visitadas
ProductRelated_Duration	Num.	Tiempo en páginas de producto (seg.)
BounceRates	Num.	Tasa de rebote (Google Analytics)
ExitRates	Num.	Tasa de salida de las páginas visitadas
PageValues	Num.	Valor promedio de las páginas visitadas
SpecialDay	Num.	Cercanía a un día especial (0-1)
Month	Categ.	Mes de la sesión
OperatingSystems	Categ.	Sistema operativo del visitante
Browser	Categ.	Navegador utilizado
Region	Categ.	Región geográfica del visitante
TrafficType	Categ.	Tipo de tráfico (búsqueda, directo...)
VisitorType	Categ.	Nuevo, recurrente o de otro tipo
Weekend	Binaria	True si la visita fue en fin de semana
Revenue	Binaria	Target: True si hubo compra

Proyecto 3: Optimización de Campañas de Telemarketing Bancario

 Sector: Banca — 41,188 registros — 21 variables

Objetivo de Negocio

Maximizar la efectividad de campañas telefónicas para la suscripción a **depósitos a plazo fijo**. El modelo debe identificar qué clientes tienen mayor probabilidad de aceptar, reduciendo el número de llamadas necesarias y mejorando el ROI de la campaña.

Contexto

Datos reales de un **banco portugués** con campañas telefónicas realizadas entre mayo 2008 y noviembre 2010. Incluye datos demográficos del cliente, historial de contacto previo e **indicadores macroeconómicos** (Euribor, índice de confianza del consumidor). Publicado por Moro et al. en UCI ML Repository.

Datos Clave

- **Fuente:** UCI ML Repository
- **Registros:** 41,188
- **Variables:** 21
- **Target:** y (yes/no)
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↑ Tasa de suscripción
- ↓ Costo por cliente
- ↑ Eficiencia del call center

Proyecto 3: Diccionario de Datos

 Bank Marketing — Variables Principales

Variable	Tipo	Descripción
age	Num.	Edad del cliente
job	Categ.	Ocupación (admin, blue-collar, technician...)
marital / education	Categ.	Estado civil y nivel educativo
default / housing / loan	Binaria	Morosidad, hipoteca y préstamo personal
contact	Categ.	Medio de contacto (celular, teléfono)
month / day_of_week	Categ.	Fecha del último contacto
duration	Num.	Duración de la llamada (seg.)
campaign	Num.	Núm. de contactos en esta campaña
pdays / previous	Num.	Días y contactos de campaña anterior
emp.var.rate	Num.	Tasa de variación del empleo
cons.price.idx	Num.	Índice de precios al consumidor
euribor3m	Num.	Tasa Euribor a 3 meses
y	Binaria	Target: Suscribió depósito a plazo

Proyecto 4: Gestión de Riesgo Crediticio

 Sector: Banca / Fintech — 30,000 registros — 25 variables

Objetivo de Negocio

Predecir qué clientes de tarjeta de crédito caerán en **mora el próximo mes**, permitiendo al banco tomar acciones preventivas: ajustar límites de crédito, ofrecer planes de pago, o priorizar la gestión de cobranza antes de que la deuda se deteriore.

Contexto

Datos reales de **30,000 clientes de tarjeta de crédito en Taiwán** (abril–septiembre 2005). Incluye información demográfica, límite de crédito, historial de pagos de los últimos 6 meses, montos facturados y montos pagados. Publicado en UCI ML Repository por Yeh & Lien (2009).

Datos Clave

- **Fuente:** UCI ML Repository
- **Registros:** 30,000
- **Variables:** 25
- **Target:** default payment
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↓ Tasa de morosidad
- ↓ Pérdidas en cartera
- ↑ Salud financiera

Proyecto 4: Diccionario de Datos

Default of Credit Card Clients — Variables Principales

Variable	Tipo	Descripción
— Datos Demográficos —		
LIMIT_BAL	Num.	Límite de crédito otorgado (NT\$)
SEX	Categ.	1=Masculino, 2=Femenino
EDUCATION	Categ.	1=Posgrado, 2=Universidad, 3=Secundaria
MARRIAGE	Categ.	1=Casado, 2=Soltero, 3=Otro
AGE	Num.	Edad del cliente
— Historial de Pago (6 meses) —		
PAY_0 a PAY_6	Categ.	Estado de pago mensual (-1=puntual, 1=1 mes atraso...)
— Montos Facturados y Pagados —		
BILL_AMT1--6	Num.	Monto facturado cada mes (NT\$)
PAY_AMT1--6	Num.	Monto pagado cada mes (NT\$)
default payment	Binaria	Target: 1 si cae en mora al mes siguiente

Nota: NT\$ = Nuevo Dólar Taiwanés. Los datos cubren 6 meses consecutivos de historial crediticio.

Proyecto 5: Segmentación Socioeconómica para Marketing

 Sector: Marketing / Consultoría — 48,842 registros — 15 variables

Objetivo de Negocio

Segmentar la población según su nivel de ingreso ($\geq 50K$ o $\leq 50K$ USD anuales) para diseñar estrategias de marketing diferenciadas. Permite a empresas de retail, banca y servicios **personalizar ofertas, precios y canales** según el perfil socioeconómico del cliente potencial.

Contexto

Extraído del **Censo de EE.UU. de 1994** (Current Population Survey). Contiene datos demográficos, laborales y educativos de casi 49,000 personas. Es uno de los datasets más clásicos en ML para clasificación. Publicado en UCI ML Repository por Kohavi & Becker.

Datos Clave

- **Fuente:** UCI ML Repository
- **Registros:** 48,842
- **Variables:** 15
- **Target:** class
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↑ Precisión en targeting
- ↑ ROI de campañas
- ↓ Desperdicio publicitario

Proyecto 5: Diccionario de Datos

 Adult Census Income — Todas las Variables

Variable	Tipo	Descripción
age	Num.	Edad de la persona
workclass	Categ.	Tipo de empleo (Private, Self-emp, Gov...)
fnlwgt	Num.	Peso final del censo (representatividad)
education	Categ.	Nivel educativo alcanzado
education-num	Num.	Años de educación
marital-status	Categ.	Estado civil detallado
occupation	Categ.	Ocupación (Exec-managerial, Sales...)
relationship	Categ.	Rol en el hogar (Husband, Wife, Own-child...)
race	Categ.	Grupo étnico
sex	Categ.	Género (Male / Female)
capital-gain	Num.	Ganancia de capital en el año
capital-loss	Num.	Pérdida de capital en el año
hours-per-week	Num.	Horas de trabajo semanal
native-country	Categ.	País de origen
class	Binaria	Target: $>50K$ o $\leq 50K$ anuales

Proyecto 6: Detección de Vehículos Defectuosos en Subastas

 Sector: Automotriz — 72,983 registros — 33 variables

Objetivo de Negocio

Identificar vehículos con **problemas ocultos** (“kicks” o “lemons”) **antes de comprarlos** en subastas automotrices. Un *kick* es un auto que resulta tener defectos graves que lo hacen invendible. El modelo permite a concesionarios evitar pérdidas millonarias al filtrar vehículos riesgosos.

Contexto

Datos de **subastas reales de autos usados en EE.UU.** Cada registro es un vehículo comprado en subasta con información de marca, modelo, color, kilometraje, precios de referencia (Manheim Market Report) y si resultó ser un “bad buy”. Competencia original: Kaggle “Don’t Get Kicked!”.

Datos Clave

- **Fuente:** Kaggle / OpenML
- **Registros:** 72,983
- **Variables:** 33
- **Target:** IsBadBuy
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↓ Compras defectuosas
- ↓ Costos de garantía
- ↑ Confianza del comprador

Proyecto 6: Diccionario de Datos

 Kick (Don't Get Kicked!) — Variables Principales

Variable	Tipo	Descripción
IsBadBuy	Binaria	Target: 1 si el auto resultó defectuoso
VehYear	Num.	Año del vehículo
VehicleAge	Num.	Antigüedad del vehículo (años)
Make / Model	Categ.	Marca y modelo del auto
Trim / SubModel	Categ.	Versión y subtipo del modelo
Color	Categ.	Color exterior
Transmission	Categ.	Tipo de transmisión (AUTO, MANUAL)
WheelType	Categ.	Tipo de llantas (Alloy, Covers, Special)
VehOdo	Num.	Kilómetros del odómetro
Size	Categ.	Tamaño (COMPACT, MEDIUM, LARGE...)
MMRAcq...AveragePrice	Num.	Precio promedio subasta (ref. Manheim)
MMRCurrent...Price	Num.	Precio actual de mercado (4 variantes)
VehBCost	Num.	Costo de adquisición del vehículo
WarrantyCost	Num.	Costo de garantía
IsOnlineSale	Binaria	1 si se compró en subasta online

Proyecto 7: Detección de Sitios Web Fraudulentos (Phishing)

 Sector: Ciberseguridad / Fintech — 11,055 registros — 31 variables

Objetivo de Negocio

Desarrollar un sistema automático de **detección de sitios web de phishing** que proteja a los usuarios y a la organización. Puede integrarse en navegadores corporativos, firewalls o sistemas de correo electrónico para **bloquear URLs maliciosas** antes de que el usuario interactúe con ellas.

Contexto

Dataset de **UCI ML Repository** con características extraídas de URLs reales. Cada variable describe un atributo técnico del sitio web (estructura de URL, certificado SSL, edad del dominio, tráfico web, etc.). Los valores son **-1 (sospechoso)**, **0 (neutral)**, **1 (legítimo)**.

Datos Clave

- **Fuente:** UCI / OpenML
- **Registros:** 11,055
- **Variables:** 31
- **Target:** Result
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↓ Incidentes de phishing
- ↓ Pérdidas financieras
- ↑ Confianza del usuario

Proyecto 7: Diccionario de Datos

Phishing Websites — Variables Principales

Variable	Tipo	Descripción
— Características de la URL —		
having_IP_Address	Ternaria	Si la URL usa IP en vez de dominio
URL_Length	Ternaria	Longitud anormal de la URL
Shortining_Service	Ternaria	Uso de acortador de URL (bit.ly...)
having_At_Symbol	Ternaria	Presencia de @ en la URL
Prefix_Suffix	Ternaria	Uso de guión en el dominio
— Seguridad y Dominio —		
SSLfinal_State	Ternaria	Estado del certificado SSL
Domain_registration_length	Ternaria	Duración del registro del dominio
age_of_domain	Ternaria	Antigüedad del dominio
DNSRecord	Ternaria	Existencia de registro DNS
— Popularidad y Contenido —		
web_traffic	Ternaria	Ranking de tráfico (Alexa)
Google_Index	Ternaria	Si está indexado en Google
Page_Rank	Ternaria	PageRank de Google
Result	Ternaria	Target: 1=Legítimo, -1=Phishing

¹⁵ Valores: -1 = sospechoso/phishing, 0 = neutral, 1 = legítimo/seguro

Proyecto 8: Predicción de Churn en E-Commerce

 Sector: E-Commerce / Retail — 15,000 registros — 20 variables

Objetivo de Negocio

Predcir qué clientes **abandonarán la plataforma** de e-commerce en los próximos meses. Esto permite lanzar campañas de retención dirigidas: cupones personalizados, programas de lealtad o comunicación proactiva **antes de perder al cliente**.

Contexto

Dataset comercial de una **plataforma de e-commerce** con información de 15,000 clientes. Incluye datos demográficos, comportamiento de compra (frecuencia, valor promedio, categoría preferida), canales de adquisición, uso de dispositivos y métricas de satisfacción. El 18 % de los clientes presentan churn.

Datos Clave

- **Fuente:** Dataset comercial
- **Registros:** 15,000
- **Variables:** 20
- **Target:** churn
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↓ Tasa de abandono
- ↑ Lifetime Value (LTV)
- ↑ Retorno de inversión

Proyecto 8: Diccionario de Datos

E-Commerce Customer Churn — Todas las Variables

Variable	Tipo	Descripción
customer_id	ID	Identificador único del cliente
age / gender	Num./Cat.	Edad y género del cliente
annual_income	Num.	Ingreso anual estimado (USD)
membership_years	Num.	Años como miembro de la plataforma
total_purchases	Num.	Total de compras realizadas
avg_order_value	Num.	Valor promedio por pedido (USD)
total_spend	Num.	Gasto total acumulado (USD)
days_since_last_purchase	Num.	Días desde la última compra
num_returns	Num.	Número de devoluciones
customer_satisfaction	Num.	Puntaje de satisfacción (1-5)
preferred_category	Categ.	Categoría favorita de compra
payment_method	Categ.	Método de pago preferido
device_type	Categ.	Dispositivo principal (Mobile, Desktop...)
avg_session_duration	Num.	Duración promedio de sesión (min.)
discount_usage_rate	Num.	Tasa de uso de descuentos (0-1)
referral_source	Categ.	Fuente de adquisición del cliente
city_tier	Categ.	Clasificación de ciudad (Tier 1, 2, 3)
churn	Binaria	Target: 1 si el cliente abandonó

Proyecto 9: Detección de Fraude en Reclamaciones de Seguros

 Sector: Seguros — 12,000 registros — 19 variables

Objetivo de Negocio

Detectar **reclamaciones fraudulentas** de seguros antes de su aprobación. El fraude en seguros representa entre el 5 % y 10 % del total de reclamaciones a nivel mundial. Un modelo predictivo permite priorizar la investigación humana en los casos más sospechosos, **reduciendo pérdidas y tiempos de revisión.**

Contexto

Dataset de una **compañía de seguros multirramo** (auto, salud, vida, hogar, viaje) con 12,000 reclamaciones. Incluye datos del asegurado (edad, educación, ingreso, puntaje crediticio), detalles de la póliza y características de la reclamación. El 6 % de las reclamaciones están marcadas como fraude.

Datos Clave

- **Fuente:** Dataset comercial
- **Registros:** 12,000
- **Variables:** 19
- **Target:** fraud_flag
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↓ Pérdidas por fraude
- ↓ Tiempo de investigación
- ↑ Ratio de detección

Proyecto 9: Diccionario de Datos

Insurance Claims Fraud — Variables Principales

Variable	Tipo	Descripción
policy_holder_age	Num.	Edad del asegurado
gender / marital_status	Categ.	Género y estado civil
education_level	Categ.	Nivel educativo
annual_income	Num.	Ingreso anual (USD)
credit_score	Num.	Puntaje crediticio (300-850)
policy_type	Categ.	Tipo de seguro (Auto, Health, Life...)
coverage_amount	Num.	Monto de cobertura (USD)
monthly_premium	Num.	Prima mensual (USD)
deductible	Num.	Deducible (USD)
years_as_customer	Num.	Años como cliente
claim_amount	Num.	Monto reclamado (USD)
num_previous_claims	Num.	Reclamaciones previas
risk_score	Num.	Puntaje de riesgo interno (0-1)
claim_status	Categ.	Estado (Approved, Denied, Pending...)
fraud_flag	Binaria	Target: 1 si es fraude

Proyecto 10: Retención de Talento Empresarial

 Sector: Recursos Humanos — 14,000 registros — 20 variables

Objetivo de Negocio

Predecir qué empleados tienen alta probabilidad de **abandonar la empresa** en los próximos meses. El costo de reemplazo de un empleado puede ser entre el 50 % y 200 % de su salario anual. El modelo permite a RRHH implementar acciones preventivas: ajustes salariales, planes de desarrollo o mejoras en el ambiente laboral.

Contexto

Dataset de una **empresa multinacional** con 14,000 empleados de 8 departamentos distintos. Incluye datos demográficos, información laboral (salario, nivel, proyectos), métricas de desempeño, satisfacción y balance vida-trabajo. La tasa de rotación es del 16 %.

Datos Clave

- **Fuente:** Dataset comercial
- **Registros:** 14,000
- **Variables:** 20
- **Target:** attrition
- **Tipo:** Clasificación binaria

Impacto Esperado

- ↓ Rotación de personal
- ↓ Costos de contratación
- ↑ Retención de talento

Proyecto 10: Diccionario de Datos

Employee Performance & Retention — Variables Principales

Variable	Tipo	Descripción
age / gender	Num./Cat.	Edad y género del empleado
education	Categ.	Nivel educativo
distance_from_home_km	Num.	Distancia al trabajo (km)
num_companies_worked	Num.	Empresas anteriores
department	Categ.	Departamento (Sales, Engineering...)
job_level	Num.	Nivel jerárquico (1-5)
years_at_company	Num.	Antigüedad en la empresa
years_in_current_role	Num.	Años en el rol actual
monthly_salary	Num.	Salario mensual (USD)
overtime_hours	Num.	Horas extra mensuales
stock_option_level	Num.	Opciones accionarias (0-3)
performance_rating	Num.	Calificación de desempeño (1-5)
job_satisfaction	Num.	Satisfacción laboral (1-5)
work_life_balance	Num.	Balance vida-trabajo (1-5)
relationship_w_manager	Num.	Relación con el jefe (1-5)
attrition	Binaria	Target: 1 si el empleado se fue

Resumen Comparativo de los 10 Proyectos

Vista general de datasets, sectores y objetivos

#	Proyecto	Registros	Vars.	Sector
1	Cancelaciones Hoteleras	119,390	32	Hotelería
2	Conversión E-Commerce	12,330	18	E-Commerce
3	Telemarketing Bancario	41,188	21	Banca
4	Riesgo Crediticio	30,000	25	Fintech
5	Segmentación por Ingreso	48,842	15	Marketing
6	Subastas Automotrices	72,983	33	Automotriz
7	Detección de Phishing	11,055	31	Ciberseguridad
8	Churn E-Commerce	15,000	20	Retail
9	Fraude en Seguros	12,000	19	Seguros
10	Retención de Talento	14,000	20	RRHH
Total		376,788		8 sectores

Todos los proyectos son de clasificación binaria. Metodología común de evaluación (AUC-ROC, precisión, recall, F1-score).



Cartera de Proyectos de **Data Analytics**